

关于线性拟合与非线性拟合的实验报告

摘要

本实验主要研究线性及非线性拟合问题，首先采用最小二乘法、梯度下降法、牛顿法完成线性模型 $y = \omega x + b$ 的拟合实验，系统分析三种算法的核心原理、收敛特性及误差表现的差异性；针对线性模型无法捕捉数据非线性特征导致拟合效果不佳的问题，分别构建三频三角函数模型与 kernel 核模型进行非线性拟合，对比两种模型的拟合精度与工程实用性，最终选择 kernel 核模型作为最优拟合方案。实验结果表明：线性模型下最小二乘法与牛顿法收敛至全局最优解，梯度下降法受超参数影响存在微小偏差，三种算法 MSE 均约 0.6，拟合能力受限；三频三角函数模型虽能捕捉数据周期特征，MSE 有所下降，但存在模型泛化能力弱、参数调优复杂等问题；kernel 核模型通过核技巧将数据映射至高维特征空间，无需人工预设函数形式，训练集与测试集 MSE 均显著降低，且泛化能力、拟合灵活性优于三频三角函数模型。

关键词：最小二乘法、梯度下降法、牛顿法、三频三角函数模型、kernel 核模型

一、引言

在数据科学与工程建模的回归拟合任务中，算法选择与模型架构设计是决定拟合效果的两大核心因素，而模型架构的合理性对拟合结果的影响远高于算法本身。针对二维非线性回归数据，单一线性模型因无法捕捉数据的非线性、周期性特征，往往拟合效果不佳；而非线性拟合模型的选择则需兼顾拟合精度、泛化能力与工程实用性。

本实验围绕数据集展开两阶段拟合研究：第一阶段采用最小二乘法、梯度下降法、牛顿法三种经典优化算法完成线性模型拟合；第二阶段针对数据的非线性特征，分别构建三频三角函数模型与 kernel 核模型进行非线性拟合。

二、评价指标

实验采用均方误差（MSE）作为模型拟合效果的核心量化指标，MSE 反映

模型预测值与真实值的平均平方偏差，数值越小表示拟合精度越高，计算公式为：

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

其中 n 为样本数量， y_i 为第 i 个样本的真实值， $\hat{y}_i$ 为模型对第 i 个样本的预测值。实验分别计算各模型在训练集与测试集上的 MSE ，综合评价模型的拟合精度与泛化能力；同时结合模型灵活性、参数调优难度、工程实现复杂度作为定性评价指标。

三、线性模型拟合实验

3.1 三种线性算法的收敛特性分析

最小二乘法：无迭代过程，通过正规方程直接求解全局最优解，收敛性与数据无关，只要特征矩阵 $X^T X$ 可逆，即可得到唯一最优解，收敛结果稳定，无超参数影响。

牛顿法：利用海森矩阵包含的二阶导数信息，对目标函数进行二次泰勒近似，收敛速度为平方级，仅需少量迭代即可收敛至全局最优解，收敛效率远高于梯度下降法，且受超参数影响小。

梯度下降法：仅利用一阶梯度信息，收敛速度为线性级，收敛结果受学习率与迭代次数影响显著：学习率过小会导致收敛缓慢，学习率过大会导致参数震荡不收敛，迭代次数不足则无法逼近最优解，易出现局部最优或参数偏差。

3.2 拟合结果与误差表现

三种算法对线性模型的拟合参数与训练与测试集 MSE 结果如表 1 所示：

表 1 线性算法拟合结果及误差分析

算法模型	拟合函数	训练集 MSE	测试集 MSE
最小二乘法	$y = 0.108947x - 0.648747$	0.613402	0.595043
梯度下降法	$y = 0.086970x - 0.502584$	0.618825	0.594021
牛顿法	$y = 0.108947x - 0.648747$	0.613402	0.595043




图 1 最小二乘法拟合图像




图 2 梯度下降法拟合图像




图 3 牛顿法拟合图像

最小二乘法与牛顿法的拟合参数、MSE 完全一致，验证了线性模型下最优解的唯一性，两种算法均能收敛至全局最优。

梯度下降法的拟合参数存在微小偏差，训练集 MSE 略高于前两者，测试集 MSE 则较低，体现了超参数对梯度下降法的影响。

三种算法的 MSE 均约 0.6，拟合精度较低，且拟合直线仅能捕捉数据的整体上升趋势，无法反映局部周期性波动，表明线性模型的表达能力与本实验数据的特征不匹配，模型架构的局限性是拟合效果不佳的核心原因。

四、非线性拟合实验

4.1 模型构建与原理

结合数据的周期性波动特征，构建线性和三频三角函数复合模型。通过人工预设的函数形式匹配数据的线性与周期特征，利用曲线拟合算法求解最优参数，属于参数化非线性模型，拟合能力依赖于人工预设的函数形式是否与数据特征匹配。

kernel 核模型无需人工预设函数形式，核心原理为：通过核函数将低维非线性可分数据映射至高维特征空间，在高维空间中实现线性回归，从而间接解决低维空间的非线性回归问题。

实验选择高斯核（RBF）作为核函数，其表达式为：

$$K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2)$$

其中， γ 为核函数带宽，是模型核心超参数；同时引入岭回归的正则化参数 α ，抑制模型过拟合，提升泛化能力。

4.2 模型训练与拟合结果

三频三角函数拟合采用曲线拟合算法对模型参数进行优化，设置最大迭代次数 200000，精度 $1e-12$ ，通过多次调参得到最优参数，拟合结果为：

拟合方程为：

$$\begin{aligned} y = & 0.157354x - 0.953438 \\ & + 0.415715\sin(0.801295x) + 0.017093\cos(0.801295x) \\ & + 0.002032\sin(1.602591x) + 0.159246\cos(1.602591x) \\ & + 0.549182\sin(2.403886x) + 0.273360\cos(2.403886x) \end{aligned}$$

三频三角函数高精度拟合




图 4 三频三角函数拟合图像

该模型的训练集 MSE 为 0.347961，测试集 MSE 为 0.347813。

kernel 核模型选择高斯核为核函数，通过网格搜索对超参数 γ 与 α 进行寻优，拟合结果为：




图 5 kernel 核模型拟合图像

该模型的训练集 MSE 为 0.318295，测试集 MSE 为 0.331016，总体低于三频三角函数拟合法，表明了 kernel 核模型更适合用于该拟合问题。

五、实验总结与反思

本实验根据二维数据集，完成了线性模型的三种算法拟合与非线性模型的两方案拟合，系统分析了不同算法、不同模型的拟合效果与核心特性。实验结果表明，kernel 核模型通过核技巧实现了非线性数据的高精度拟合，其拟合精度、泛化能力、灵活性均优于其他模型，是本实验的最优拟合方案。

回归拟合的本质是对数据背后生成规律的挖掘，模型架构的合理选择是挖掘数据规律的核心，而算法优化仅为辅助手段。在工程实践中，应摒弃重算法、轻模型的误区，先通过数据特征分析选择匹配的模型架构，再选择合适的优化算法与超参数调优方法，才能实现高效、稳定的回归拟合。

超参数调优是提升模型性能的关键，无论是梯度下降法的学习率、还是 kernel 核模型的核带宽与正则化参数，超参数对模型效果均有显著影响；工程中应采用贝叶斯优化、网格搜索等自动化的超参数寻优方法，而非人工试错，提升调参效率与模型性能。