

基于 CNN - LSTM - Attention 的 PM 2.5 多步预测模型研究

摘要

空气污染预测是环境科学与智能计算交叉领域的重要研究方向，其中 PM2.5 浓度预测对于公共健康评估与城市管理具有重要意义。传统时间序列模型在处理非线性、多变量以及长期依赖问题时存在明显局限。为此，本文提出一种融合**卷积神经网络 CNN**、**长短期记忆网络 LSTM** 以及**注意力机制 Attention** 的混合深度学习模型，用于**多变量时间序列的多步预测**任务。模型首先通过 CNN 提取局部时序特征，再利用 LSTM 捕捉长期依赖关系，最后通过 Attention 机制对关键时间步进行加权强化，从而提升预测精度。实验基于空气质量数据集展开，通过**热力图**分析特征相关性，并构建单步与多步预测任务进行对比验证。实验结果表明，该模型在趋势拟合与峰值预测方面均表现出较高精度，同时具备良好的泛化能力。

关键词：空气污染预测，多变量时间序列建模，深度学习，CNN - LSTM 模型，注意力机制，多步预测

一、引言

随着工业化与城市化进程的加速，空气污染问题日益严峻，尤其是 PM2.5 浓度的升高已被证明对人体呼吸系统及心血管系统产生显著危害。因此，如何准确预测 PM2.5 浓度变化趋势，成为环境监测与智能预警系统中的核心问题。传统统计方法（ARIMA）在处理线性时间序列方面具有一定优势，但面对空气质量数据中复杂的非线性关系、多变量耦合以及时间依赖特性时，往往难以获得理想效果。

近年来，深度学习方法在时间序列预测领域展现出强大的建模能力。其中，LSTM 网络通过门控机制有效缓解了长序列中的梯度消失问题，能够捕捉长期依赖关系。然而单一 LSTM 结构在局部模式提取能力以及关键时间步关注能力方面仍存在不足。因此，本文尝试引入 CNN 与 Attention 机制，与 LSTM 进行融合建模，从而构建一个兼具局部

特征提取能力、长期依赖建模能力以及关键信息筛选能力的混合模型，以解决多变量空气质量预测问题。

二、数据预处理

2.1 数据来源与处理

本文所使用的数据来源于公开空气质量数据集，包含污染物浓度（`pollution`）、气象因素（温度 `temp`、露点 `dew`、气压 `press`）、风速（`wnd_spd`）、降雪（`snow`）、降雨（`rain`）以及风向（`cbwd`）等多个变量。实验中分别使用训练集与测试集进行建模与评估。

在数据预处理阶段，首先对时间字段进行标准化处理，将日期信息转换为时间索引，以便模型捕捉时间序列特征。随后对无关字段进行删除，以减少冗余信息干扰。在处理类别变量风向时，采用独热编码方式将其转换为数值特征，从而避免模型在训练过程中因类别变量引入偏差。进一步对所有特征进行数值化处理，并使用缺失值填充为 0 的策略保证数据完整性。

由于训练集与测试集可能存在特征不一致问题，本文通过对齐操作统一两者的特征空间，确保模型输入维度一致。采用 `MinMaxScaler` 对数据进行归一化处理，将不同量纲的特征映射至统一范围，从而提高模型收敛速度与稳定性。

2.2 数据相关性分析




图 1 气象数据热力图

通过相关性分析可以观察到，不同气象因素之间存在一定程度的相关性，例如温度与露点呈现较强正相关，而气压与温度呈现明显负相关。这为后续模型学习提供了重要依据。

关于热力图中的“空白区域”，其本质原因在于风向变量在独热编码后被拆分为多个独立维度，而这些维度之间不存在线性相关性，因此相关系数接近 0，表现为图中的空白区域。这并不意味着风向对污染没有影响，而是说明其影响是非线性或组合性的。

三、研究思路

3.1 模型结构

本文之所以选择 CNN - LSTM - Attention 组合模型，而非单一 LSTM，主要基于多

方面考虑。虽然 LSTM 能够建模长期依赖关系，但其对局部时间窗口内的短期变化捕捉能力较弱。而空气污染数据往往具有明显的局部波动特征，例如突发污染峰值或短时间气象变化，这正是 CNN 所擅长提取的模式。因此，引入一维卷积网络可以有效增强模型对局部特征的感知能力。

LSTM 作为核心时序建模模块，通过其输入门、遗忘门与输出门机制，能够在长时序序列中保留重要信息并遗忘无关信息，从而捕捉历史数据对未来预测的影响。然而，在实际应用中，不同时间步对预测结果的重要性并不相同，因此需要进一步引入 Attention 机制。

Attention 机制通过对 LSTM 输出的隐藏状态进行加权处理，使模型能够自动学习哪些时间步对预测结果更为关键，从而提高模型对重要信息的利用效率。最终，该模型形成了“局部特征提取—长期依赖建模—关键信息强化”的完整结构体系。




图 2 模型机制原理图

3.2 卷积神经网络 (CNN)

在时间序列任务中，一维卷积网络通过在时间轴上滑动卷积核，对相邻时间步的数据进行聚合，从而提取局部变化模式。相比直接使用原始序列输入模型，CNN 能够提前学习到更具代表性的局部特征，例如短期波动、突发变化或周期性趋势。

卷积操作的基本形式可以表示为：

$$h_t = \sigma \left(\sum_{i=0}^{k-1} \omega_i \cdot x_{t+i} + b \right)$$

其中，卷积核在时间窗口内对输入进行加权求和，并通过非线性函数进行映射。

通过该过程，模型能够从原始数据中提取出更高层次的局部特征表示。同时，MaxPooling 操作对特征进行压缩，既减少计算量，又保留最显著的信息。在空气质量预测任务中，这种机制能够有效捕捉短时间内的污染变化趋势，为后续模型提供更有意义的输入。CNN 在本模型中的主要作用是强化局部时间模式的表达能力。

3.3 长短期记忆网络（LSTM）

LSTM 网络通过引入门控结构，有效解决了传统循环神经网络在长序列建模中的信息遗失问题。其核心思想在于通过“选择性记忆”，在时间维度上保留重要信息并过滤无关信息。

LSTM 的状态更新可以简要表示为：

$$C_t = f_t \cdot C_{t-1} + i_t \cdot \tilde{C}_t$$

其中，遗忘门 f_t 控制历史信息的保留程度，输入门 i_t 决定当前信息的写入比例。

通过这种机制，LSTM 能够在长时间范围内捕捉数据之间的依赖关系。在空气污染预测中，当前污染水平往往受到过去多个时间步的影响，例如气象条件的累积效应或污染扩散过程。因此，仅依赖短期信息是不够的，必须通过 LSTM 建模长期趋势。LSTM 的作用是刻画时间序列中的长期依赖结构，实现历史信息的有效传递。

3.4 注意力机制（Attention）

尽管 LSTM 能够处理长序列信息，但其默认对所有时间步赋予相似的重要性，这在实际应用中并不合理。不同时间点对预测结果的贡献程度存在显著差异，因此需要一种机制对关键时间信息进行筛选与强化。

Attention 机制通过为每个时间步分配权重，实现对重要信息的动态关注，其核心形式可以表示为：

$$c = \sum_{t=1}^T \alpha_t \cdot h_t$$

其中，权重 α_t 反映了第 t 个时间步的重要程度。

通过这一加权过程，模型能够自动聚焦于对预测最有贡献的时间片段。在空气污染

预测中，污染快速上升前的若干时刻往往更关键，Attention 可以增强这些时间点的影响，从而提高预测精度。Attention 机制在本模型中的核心作用是突出关键时间信息，提高模型对重要特征的利用效率。

四、模型构建

在完成数据预处理之后，本文基于 TensorFlow / Keras 框架构建 CNN - LSTM - Attention 混合模型，并结合实际任务需求对模型结构及训练参数进行合理设定。

在输入数据构造阶段，将原始时间序列转化为监督学习形式。具体而言，采用滑动窗口方法，将连续 24 个时间步的数据作为输入，预测未来 3 个时间步的 PM2.5 浓度。该设置的物理意义在于：利用过去 24 小时的观测数据，对未来 3 小时的空气质量进行预测，这既符合空气污染的时间演化规律，也满足短期预测的实际应用需求。

在模型结构设计上，输入层定义为：

$$\text{Input shape} = (24, n_features)$$

其中 $n_features$ 表示多变量特征数量（包括污染物与气象因素）。该三维输入结构能够同时保留时间维度与特征维度信息。

模型首先引入一维卷积层（Conv1D），设置卷积核数量为 64，卷积核大小为 3，激活函数为 ReLU。该层的作用是对时间序列进行局部特征提取，通过滑动窗口捕捉短期变化模式。卷积层输出后，接入最大池化层（MaxPooling1D），池化大小设为 2，用于降低特征维度并增强模型的抗噪能力。

在此基础上，模型引入 LSTM 层进行时序建模，隐藏单元数设为 64，并开启 `return_sequences=True`，以保留完整时间序列输出供后续 Attention 层使用。该设计确保模型不仅能够学习长期依赖关系，还能为注意力机制提供丰富的时间步信息。

Attention 层作为模型的关键部分，对 LSTM 输出的隐藏状态进行加权整合。通过学习不同时间步的重要性权重，模型能够自动聚焦于对预测结果贡献更大的时间片段，从而提升预测性能。该层最终输出一个固定长度的上下文向量。

在输出层设计中，采用全连接层（Dense），输出维度设为 3，对应未来三个时间步的预测值。该结构实现了从单步预测向多步预测的扩展，使模型具备更强的实际应用价值。

表 1 模型结构表

Layer (type)	Output Shape	Param
input_2 (InputLayer)	(None, 24, 8)	0
conv1d_1 (Conv1D)	(None, 22, 64)	1600
max_pooling1d_1 (MaxPooling1D)	(None, 11, 64)	0
lstm_1 (LSTM)	(None, 11, 64)	33024
attention_layer_1 (AttentionLayer)	(None, 64)	75
dense_1 (Dense)	(None, 3)	195

在模型训练方面，本文采用 Adam 优化器进行参数更新，其自适应学习率机制能够加快收敛速度并提高训练稳定性。损失函数选择均方误差（MSE），用于衡量预测值与真实值之间的差异，这在回归问题中具有良好的适用性。

在训练参数设置上，批大小（batch_size）设为 64。该值在计算效率与梯度稳定性之间取得了较好的平衡：较小的 batch_size 虽然有助于提升泛化能力，但训练时间较长；而过大的 batch_size 则可能导致模型陷入局部最优。因此，64 是一种较为常见且有效的经验选择。

模型训练轮数（epoch）设为 20，该参数表示模型对整个训练数据集进行完整学习的次数。在实际训练过程中可以观察到，模型在前几个 epoch 内损失迅速下降，随后逐渐趋于平稳，说明模型已经基本收敛。将 epoch 设置为 20，既能够保证模型充分学习数据特征，又可以避免因训练轮数过多而导致的过拟合问题。在约第 10 轮之后模型性能提升趋于缓慢，因此 20 轮训练在效果与效率之间取得了合理平衡。

五、实验可视化分析

5.1 损失函数分析

从训练损失与验证损失曲线可以观察到，模型在前几个 epoch 内快速收敛，随后逐渐趋于平稳，说明模型能够有效学习数据分布且未出现明显过拟合现象。从结果来看，训练初期损失值迅速下降，说明模型能够快速学习数据中的主要模式；随着训练的进行，损失曲线逐渐趋于平稳，表明模型逐步接近最优解。同时，训练损失与验证损失之间的差距较小，未出现明显分离现象，说明模型在训练集与测试集之间具有较好的泛化能力，

没有出现显著过拟合。这一现象也从侧面验证了模型结构与参数设置的合理性。




图 3 损失曲线图

5.2 单步与多步预测

单步预测结果表明，模型在短期预测任务中具有较高精度，预测曲线能够较好地贴合真实曲线，尤其是在污染变化较为平缓的区间，拟合效果更加理想。然而，在污染快速上升或下降的阶段，模型预测存在一定的滞后现象，这主要是由于模型在面对突发变化时，对历史信息的依赖导致响应略有延迟。




图 4 单步预测图

进一步分析多步预测结果可以发现，随着预测步长的增加，模型误差逐渐累积，表

现为预测曲线与真实曲线之间的偏差增大，尤其在峰值区域更为明显。这种现象在时间序列预测中是普遍存在的，其本质原因在于模型在进行多步预测时需要基于已有预测结果进行递推，从而导致误差逐步放大。尽管存在一定偏差，模型在整体趋势上的拟合仍保持较高一致性，说明其在中短期预测范围内具有较强的稳定性与可靠性。




图 5 多步预测图

从单步预测扩展至多步预测，是因为实际应用中更关注未来一段时间的变化趋势，而非单一时刻的预测值，因此多步预测更具现实意义。

六、模型优缺点分析

本文模型的主要优势在于融合了三种不同结构的优点：CNN 提供局部特征提取能力，LSTM 捕捉长期依赖关系，而 Attention 机制则强化关键时间信息，从而显著提升预测精度。多步预测能力使模型更贴近实际应用场景。

本实验的模型也存在一定不足：例如模型结构较为复杂，训练成本较高；同时，多步预测误差随时间步增长而累积。此外，模型未显式建模的空间因素，包括地理位置等，限制了其在更复杂场景中的应用能力。

未来该模型可以通过引入 Transformer 结构、加入图神经网络等空间信息或使用更先进的时间序列模型（Temporal Fusion Transformer）进一步提升性能。

七、实验结论分析

通过对模型训练过程与预测结果的综合分析可以看出，本文所提出的 CNN - LSTM - Attention 模型在空气质量预测任务中表现出较高的有效性与稳定性。从训练过程来看，损失函数在初期迅速下降并逐步收敛，说明模型能够有效捕捉数据中的主要特征模式，并在有限训练轮数内达到较优状态。同时，训练损失与验证损失之间未出现明显分离，表明模型具备良好的泛化能力。

在预测性能方面，模型在单步预测任务中表现尤为突出，能够较准确地拟合 PM2.5 浓度的变化趋势，并在大多数时间区间内保持较低误差。这说明模型在短期预测场景下具有较高可靠性。在多步预测任务中，尽管随着预测步长增加，误差逐渐累积，但模型仍能够保持整体趋势的一致性，体现出较好的稳定性与连续预测能力。这一结果表明，模型不仅能够学习短期动态变化，还能够一定程度上刻画中期趋势。

进一步结合可视化分析可以发现，模型在处理平稳变化区间时表现更加稳定，而在污染快速变化或极端峰值区域，预测结果存在一定偏差。这表明模型对高频突变信息的捕捉仍有提升空间，同时也反映出数据本身的随机性与复杂性对预测精度的影响。

八、实验总结与反思

本实验通过构建融合 CNN、LSTM 与 Attention 的深度学习模型，实现了空气质量数据的多步预测任务。在实验过程中，不仅加深了对时间序列建模方法的理解，也认识到数据预处理与特征工程在模型性能中的关键作用。同时，笔者也发现模型复杂度与预测精度之间需要权衡。

通过本次实验，可以系统性地认识到深度学习方法在时间序列预测任务中的优势与挑战。在模型构建过程中，不同结构之间的协同作用对于提升预测性能具有重要意义。单一模型往往难以全面刻画数据特征，而多结构融合能够在不同层次上对信息进行提取与整合，从而实现更高效的建模。

未来工作中，笔者将进一步优化模型结构，引入更多外部数据，并探索更高效的训练策略，以提升模型的泛化能力与实际应用价值。