

基于 Transformer 的序列建模实验与模块必要性研究

——《Attention Is All You Need》论文复现研究报告

摘要

Transformer 模型自 2017 年被提出以来，凭借其基于自注意力机制（Self-Attention）的并行化序列建模能力，迅速成为自然语言处理领域的重要基础模型。本文以经典论文《Attention Is All You Need》为研究对象，基于 **PyTorch** 框架完成了 **Transformer** 的核心结构复现，并围绕“位置编码必要性”与“CNN 能否替代自注意力机制”两个问题展开实验研究。实验采用 toy 序列翻转任务作为基础数据集，通过构建不同位置编码形式的 **Transformer** 模型以及引入位置编码后的 **CNN Seq2Seq** 网络，对比分析不同模型在序列建模任务中的性能差异。实验结果表明：缺失位置编码会导致 **Transformer** 无法有效学习序列顺序关系，其验证准确率仅为 43.79%；而引入正弦位置编码后，模型准确率可提升至 99.83%。同时，加入位置编码后的 **CNN Seq2Seq** 网络也能够取得较高精度，但其本质仍偏向局部特征提取，在长距离依赖建模能力上与 **Transformer** 存在差异。进一步地，本文通过 Attention Heatmap 对不同位置编码下的注意力分布进行了可视化分析，从模型可解释性的角度验证了位置编码对注意力学习的重要作用。本实验不仅复现了 **Transformer** 的核心思想，也进一步加深了对自注意力机制与序列建模本质的理解。

关键词：Transformer，位置编码，自注意力机制，PyTorch 框架，CNN Seq2Seq

一、引言

随着深度学习的发展，序列建模逐渐成为自然语言处理领域中的核心问题。传统循环神经网络（RNN）虽然能够处理序列数据，但由于其结构具有严格的时间依赖性，导致模型难以并行计算，同时在长序列任务中容易出现梯度消失与

长距离依赖丢失等问题。随后出现的 LSTM 与 GRU 虽然在一定程度上缓解了上述问题，但其本质仍然依赖时间步递归结构，因此训练效率与长距离建模能力仍受到限制。在此背景下，Google 于 2017 年提出 Transformer 模型，并在论文《Attention Is All You Need》中首次完全抛弃循环结构，仅利用自注意力机制完成序列建模。这一思想突破了传统序列网络的结构限制，使模型能够实现高度并行化训练，同时显著增强了对长距离依赖关系的学习能力。

然而，Transformer 并非完美结构。由于自注意力机制本身不具备位置信息感知能力，因此模型无法天然区分输入 token 的顺序关系。为解决这一问题，论文中引入了位置编码（Positional Encoding）模块，通过人为向输入嵌入位置信息，使模型能够理解序列顺序。Transformer 的核心结构建立在 Query、Key 与 Value 的注意力映射之上，其本质属于全局特征建模方式，与传统 CNN 的局部感受野建模方式存在明显区别。

因此，一个值得研究的问题是：如果在 CNN 中加入位置编码，是否能够在一定程度上替代 Transformer 的全局自注意力机制；与此同时，位置编码本身又是否真的决定了 Transformer 的序列理解能力。

基于上述问题，本文围绕 Transformer 的核心模块展开实验研究，重点分析位置编码在 Transformer 中的必要性，并进一步比较 Transformer 与 CNN Seq2Seq 在引入位置编码后的性能差异。通过实验验证不同模块对模型性能的影响，从而更加深入地理解 Transformer 的结构本质与工作机制。

二、数据生成与处理

本实验并未直接采用大规模自然语言数据集，而是使用人工构建的 toy 序列翻转任务作为基础实验数据。选择该任务的主要原因在于，其能够在较低计算资源消耗下，清晰地验证模型对序列顺序关系与长距离依赖关系的学习能力。实验中随机生成一定长度的整数序列作为输入，例如 [3, 8, 1, 5, 2]，对应输出为其翻转序列 [2, 5, 1, 8, 3]。由于该任务高度依赖序列位置关系，因此非常适合用于研究位置编码与注意力机制的作用。

在数据生成过程中，程序通过 ReverseDataset 类动态随机生成序列数据，并统一设置词表大小、序列长度以及 padding token。由于不同样本序列长度可

能存在差异，因此在 DataLoader 中通过 `collate_fn` 函数对序列进行 padding 操作，使同一 batch 中的数据维度保持一致。为了避免 padding token 对模型训练造成干扰，实验中进一步构建了 mask 机制，在注意力计算与损失计算时自动忽略 padding 部分。与此同时，实验将数据划分为训练集、验证集与测试集，并通过批量加载方式提高 CPU 环境下的数据读取效率。

在模型输入阶段，所有 token 首先经过 embedding 映射为高维向量表示，然后再根据不同实验需求决定是否加入位置编码。对于 Transformer 模型而言，位置编码与 token embedding 进行逐元素相加；而对于 CNN Seq2Seq 模型，则将位置信息作为卷积输入的一部分，使卷积网络能够一定程度感知序列顺序关系。通过这一数据处理流程，实验能够在统一数据环境下公平比较不同模型结构的性能差异。

三、研究思路

本实验共包含两个核心研究方向。第一个实验主要研究位置编码在 Transformer 中的必要性；第二个实验则重点研究 CNN 在引入位置编码后能否替代 Transformer 的自注意力机制。

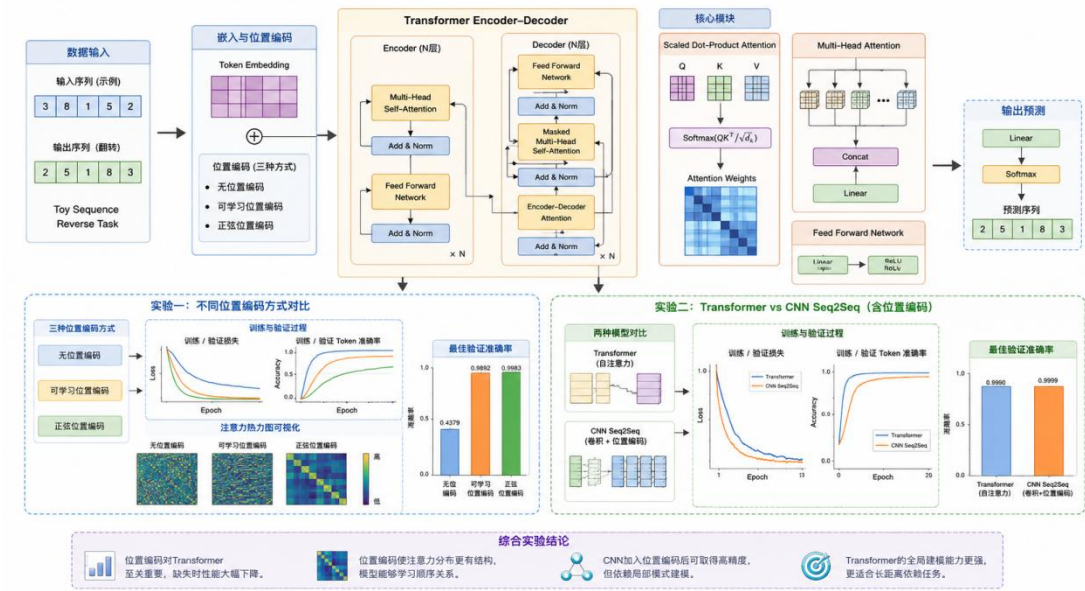


图 1 机制原理图

3.1 位置编码的影响

在第一个实验中，本文分别构建了三种不同的位置编码方式，包括“无位置编码”、“可学习位置编码”以及原论文提出的“正弦位置编码”。由于自注意力机制本身只关注 token 间的相似性，而不具备序列顺序感知能力，因此如果完全移除位置编码，模型理论上将无法区分输入序列中 token 的先后顺序。实验通过对比不同位置编码下模型的收敛速度与最终准确率，从而分析位置信息对于 Transformer 的重要程度。此外，为了提高实验可解释性，本文还引入 Attention Heatmap 对注意力分布进行可视化分析。通过观察不同位置编码下注意力权重的空间分布，可以更加直观地理解 Transformer 如何学习序列中的位置关系。

3.2 CNN 与 Transformer 的比较

第二个实验则围绕“自注意力机制是否可被卷积结构替代”展开研究。CNN 本质上属于局部特征提取网络，其感受野依赖卷积核大小逐层扩展，因此在长距离依赖建模能力上天然弱于 Transformer 的全局注意力机制。然而，如果在 CNN 中加入位置编码，理论上卷积网络也能够学习一定的序列顺序关系。因此，本文构建了 CNN Seq2Seq 模型，并将其与 Transformer 放置于相同实验环境下进行比较。实验重点关注两类模型在训练收敛速度、验证准确率以及长距离依赖学习能力上的差异，从而分析卷积结构与自注意力机制在序列建模任务中的本质区别。

四、模型构建

在 Transformer 模型构建过程中，实验严格参考《Attention Is All You Need》中的核心结构设计。模型整体采用 Encoder-Decoder 框架，每个 Encoder 层均由 Multi-Head Self-Attention 与 Feed Forward Network 组成，并通过残差连接（Residual Connection）与 Layer Normalization 保证深层网络训练稳定性。实验中隐藏层维度 `d_model` 设置为 128，多头注意力头数 `num_heads` 设置为 8，前馈网络维度 `d_ff` 设置为 512。这些参数设置主要基于 toy 数据集规模较小以及 CPU 环境下训练效率的综合考虑。若维度设置过大，会显著增加训练时间；而维度过小则可能降低模型表达能力，因此最终选择中等规模参数作为实验平衡点。

位置编码实验中，三种不同位置编码方式分别通过独立模块实现。无位置编

码模型直接将 token embedding 输入 Encoder；可学习位置编码模型通过训练一个可更新的位置 embedding 矩阵学习位置信息；正弦位置编码则采用原论文中的周期函数形式，通过不同频率的正弦与余弦函数生成固定位置向量。由于正弦位置编码具有良好的相对位置泛化能力，因此其在实验中表现最稳定。

在 CNN Seq2Seq 模型构建过程中，实验采用多层卷积结构替代 Transformer 中的自注意力模块。Encoder 与 Decoder 均由一维卷积层堆叠组成，并在卷积后加入 GLU 激活函数与残差连接结构，以增强网络表达能力并缓解深层卷积训练中的梯度问题。卷积核大小 kernel_size 设置为 3，使模型能够在局部窗口内提取序列特征。为了增强 CNN 对序列顺序的理解能力，实验同样加入了位置编码模块，并与 token embedding 进行融合输入。

模型训练阶段统一采用 Adam 优化器，并使用 Transformer 原论文中的 warmup 学习率调度策略。实验中 warmup steps 设置为 4000，同时加入 label smoothing 技术缓解模型过拟合问题。由于实验环境仅为 CPU，因此 batch size 设置为 32，以兼顾训练速度与内存消耗。

五、实验可视化分析

在位置编码实验中，模型训练曲线表现出明显差异。




图 2 不同位置编码方式对比曲线图

从图中可以观察到，无位置编码模型的 loss 长时间维持在较高水平，验证准确率始终无法有效提升，最终仅达到约 43.79%。这一现象说明 Transformer 在缺失位置信息时几乎无法正确学习序列翻转任务，因为模型无法区分 token 的先后顺序。而加入可学习位置编码与正弦位置编码后，模型均能够快速收敛，并在约 10 个 epoch 内达到较高精度，其中正弦位置编码最终验证准确率达到

99.83%，略优于可学习位置编码。




图 3 实验一最佳验证准确率柱状图

该图进一步说明位置编码对于 Transformer 的必要性。无位置编码模型性能远低于其他两种模型，而加入位置信息后模型准确率几乎提升至完全正确水平，验证了位置编码是 Transformer 理解序列顺序关系的重要前提。




图 4 无位置编码 Attention 热力图

从热力图中可以明显观察到，无位置编码时模型注意力分布较为混乱，缺乏

清晰结构，说明模型无法稳定关注序列中的对应位置。而在加入位置编码后，注意力权重通常会逐渐呈现对角线结构，说明模型已经能够学习 token 之间的位置对应关系。这一现象从可解释性角度进一步验证了位置编码对 Transformer 的重要意义。




图 5 实验二训练曲线图




图 6 实验二准确率柱状图

从实验结果来看，CNN Seq2Seq 在引入位置编码后同样能够取得极高准确率，甚至略高于 Transformer。但从训练过程可以发现，Transformer 的收敛过程更加稳定，而 CNN 的高精度更多建立在局部卷积模式提取基础之上。在 toy 数据集规模较小的情况下，两类模型差异并不明显；但若扩展至长文本任务，自注意力机制的全局建模优势将更加突出。

表 1 两项实验数据结果表

	最佳验证准确率	最佳验证损失
无位置编码	0.4379	1.5906
可学习位置编码	0.9892	0.5919
正弦位置编码	0.9983	0.5702
Transformer	0.9990	0.5690
CNN Seq2Seq	0.9999	0.5654




图 7 两项实验综合准确率汇总图

六、模型的比较与分析

Transformer 的最大优势在于其全局自注意力机制能够直接建立任意位置 token 之间的联系，因此在长距离依赖建模任务中具有天然优势。同时，由于 Transformer 不依赖循环结构，因此能够实现高度并行化训练，大幅提升模型训练效率。此外，Attention 机制还具有较强可解释性，可以通过 Heatmap 直观观察模型关注区域。然而，Transformer 的计算复杂度与序列长度平方成正比，因此在长序列任务中会带来较高显存与计算开销。

相比之下，CNN Seq2Seq 的卷积结构更加轻量化，其局部卷积操作在计算效率上通常优于全局注意力机制。同时，卷积结构天然适合提取局部模式特征，因此在短序列或局部模式明显任务中能够取得较好效果。但 CNN 的感受野本质仍受卷积层数限制，因此在超长序列任务中，其长距离依赖学习能力通常不如

Transformer。此外，CNN 对序列顺序关系的学习高度依赖人为加入的位置编码，否则模型难以建立稳定时序关系。

未来可以考虑引入更高效的注意力机制，例如 Sparse Attention、Linear Attention 或 Performer 等结构，以降低 Transformer 在长序列任务中的计算复杂度。同时，也可以进一步研究 CNN 与 Attention 混合结构，例如 Conformer 或 ConvTransformer，从而兼顾局部特征提取能力与全局依赖建模能力。

七、实验结论分析

本实验围绕 Transformer 的位置编码与自注意力机制展开研究，并通过两个实验验证了 Transformer 各模块的重要性。实验结果表明，位置编码对于 Transformer 的序列建模能力具有决定性作用。当模型缺失位置信息时，其性能会急剧下降，说明自注意力机制本身无法感知 token 顺序关系。而加入位置编码后，模型能够快速学习序列中的位置对应关系，并显著提升预测精度。

与此同时，CNN Seq2Seq 在加入位置编码后也能够取得较高性能，这说明卷积结构同样具备一定序列建模能力。然而，从模型本质来看，CNN 更偏向局部模式提取，而 Transformer 的全局自注意力机制在长距离依赖学习与全局关系建模方面仍具有明显优势。因此，Transformer 的核心价值不仅仅在于并行化训练，更在于其能够动态建立全局 token 关联关系。

Attention Heatmap 的可视化结果进一步说明，位置编码实际上改变了模型注意力权重的空间分布，使模型能够形成稳定的位置映射关系。这一现象从模型内部机制角度验证了 Transformer 的工作原理。

八、实验总结与反思

通过本次实验，对 Transformer 的核心结构与工作机制有了更加深入的理解。相比于单纯阅读论文，亲自复现模型并观察不同模块对性能的影响，更能够理解自注意力机制、位置编码以及卷积结构之间的本质区别。尤其是在位置编码实验中，可以明显感受到位置信息对于序列建模的重要性，这也进一步说明 Transformer 虽然强大，但其仍然需要人为提供一定结构先验。

与此同时，本实验也存在一定局限性。由于计算资源限制，实验采用的是 toy

序列翻转任务，而非真实自然语言数据集，因此模型之间的差异可能未被完全放大。此外，实验主要在 CPU 环境下完成，因此模型规模与训练轮数均受到一定限制。未来若能够在 GPU 环境下扩展至机器翻译、文本摘要等真实 NLP 任务，将能够更加全面地验证 Transformer 与 CNN 在复杂序列建模中的性能差异。

本实验不仅完成了《Attention Is All You Need》的基础复现，也通过模块消融实验进一步验证了 Transformer 中位置编码与自注意力机制的重要性，对后续深入研究大语言模型与现代 Transformer 架构具有重要意义。